

Morphology

- Morphology is the part of grammar that addresses the inner structure of words
- While English has a rather impoverished morphology, other languages have a much richer one (e.g., Hebrew)
- Morphological analysis is the decomposition of words into their sub-parts and the structure that combines them
- In NLP, morphological analysis minimally involves segmentation into tokens (the minimal units of analysis)
 - There are many tokenization schemes

Morphological Analysis in NLP

- Basic tokenization: (mostly separating out clitics)
 - In English, mostly involves separating out apostrophes:
 - isn't → is+n't
 - let's → let+'s
 - Dina's --> Dina+'s
 - ספר, ה', בית, ל' will turn into ['ל', 'בית', 'ה', 'ספר']
 - Auf'm → auf 'm (German: auf+dem)
- Lemmatization: mapping to the base form
 - dogs → dog
 - כלבים → כלב
 - כלב → كلب (lit. dogs → dog)
 - takes → take
 - נתן → יתנו

Segmentation into Morphemes

- Some languages combine words into compounds or other morphologically complex structures
 - *renewal* → *re* + *new* + *al*
 - *German: nachgedacht* → *nach* + *ge__t* + *dach* (lemma: *denken*)
 - *מטבחונים* → *ים* + *ון* + *מטבח*

Tokenization of a Hebrew Sentence

1	כתובת	כתובת			
2-3	בארמנית	–			
2	ב	ב			
3	ארמנית	ארמנית	19-20	בציפורים	–
4-5	המתנוססת	–	19	ב	ב
4	ה	ה	20	ציפורים	ציפור
5	מתנוססת	התנוסס	21	שונות	שונה
6-7	בראש	–	22	,	,
6	ב	ב	23-24	בכלים	–
7	ראש	ראש	23	ב	ב
8-9	הפסיפס	–	24	כלים	כלי
8	ה	ה	25-27	ובפירות	–
9	פסיפס	פסיפס	25	ו	ו
10	,	,	26	ב	ב
11-12	וכן	–	27	פירות	פרי
11	ו	ו	28	,	,
12	כן	כן	29	מלמדים	לימד
13-14	סגנונו	–	30	כי	כי
13	סגנון	סגנון	31	נעשה	נעשה
14	ו	הוא	32	בידי	בידי
15-16	האמנותי	–	33	אמנים	אמן
15	ה	ה	34	ארמנים	ארמן
16	אמנותי	אמנותי	35	.	.
17-18	העשיר	–			
17	ה	ה			
18	עשיר	עשיר			