

תאריך: 12.2.2023

מבחן מועד א' בקורס עיבוד שפה טבעית (67658)

שנת לימודים התשפ"ג 2022/2023

משך המבחן: שעותיים

מרצה הקורס: פרופ' עמרי אבנר

השימוש בכל חומר עזר אסור, נא כתבו על הכריכה על אילו שאלות עניתם.

חלק א' (80 נקודות): ענו על בדיוק שתי שאלות מבין שאלות 1-3

שאלה 1 (40 נקודות):

נתבונן במשימת Named Entity Recognition ונניח שסוגי הישויות האפשריות הם: {Person, Organization, Location}

זיהוי שאר סוגי ה-named entities לא נכללים בהגדרת משימה זו.

לדוגמא, עבור הקלט:

(1) Yossi saw the movie Jurassic Park in Tel Aviv

הפלט הנדרש יהיה:

(2) [Yossi]_{Person} saw the movie Jurassic Park in [Tel Aviv]_{Location}

א. (7 נק') הציעו מודל Bigram CRF (Conditional Random Field) עבור משימה זאת. אין צורך לפרט כיצד מתבצע האימון או ההיסק (inference), אלא רק לרשום את ההגדרה הפורמלית של המודל, והגדרת כל רכיב המופיע בה.

ב. (25 נק') נתבונן במודל שהגדרתם בסעיף א', ונניח שהפרמטרים של המודל נתונים (כלומר המודל מאומן).

קעת נרצה לתייג באמצעות המודל משפט נתון (נסמן את מילותיו ב- $x_1, \dots, x_n$). נניח שידוע:

A. שהמילה הראשונה במשפט היא named entity באורך בדיוק 1 מסוג Person וגם

B. שהמילה האחרונה במשפט היא חלק מ-named entity באורך לפחות 1 מסוג Location

כתבו אלגוריתם המקבל משפט ותיוג אפשרי $y_1, \dots, y_n$ ומחשב את ההסתברות (ע"פ המודל המאומן) של

התיוג עבור המשפט בהינתן שהנחות (A) ו-(B) מתקיימות, כלומר את

$$P(y_1, \dots, y_n | x_1, \dots, x_n, A, B)$$

ג. (8 נק') כיצד היה משתנה האלגוריתם בסעיף ב' אם היה מדובר במודל MEMM ולא במודל CRF?

שאלה 2 (40 נקודות):

לאורך שאלה זו נניח שמודל השפה בו אנו עוסקים הוא Markov Language Model מסדר שני (Trigram). קעת נגדיר **דגימה באמצעות טמפרטורה** ממודל השפה. נסמן את ההתפלגות שמגדיר מודל שפה נתון על המילה הבאה w

בהינתן רישא s (prefix), $P(w|s)$. בהינתן $T > 0$ ממשי, נגדיר את ההתפלגות (V הוא אוצר המילים):

$$P_T(x|s) = \frac{P(x|s)^{T-1}}{\sum_{x' \in V} P(x'|s)^{T-1}}$$

כדי לבצע דגימה באמצעות טמפרטורה מהמודל, נדגום בכל שלב i מילה x_i באופן מקרי על פי ההתפלגות $P_T(x_i|x_{i-1}, \dots, x_0)$

נניח ש- $x_0 = \text{START}$. נחזור על הדגימה עד ש- $x_i = \text{STOP}$.

א. (5 נק') הגדירו באופן פורמלי מודל שפה מרקובי מסדר שני. מהם הפרמטרים של המודל?

ב. (5 נק') הראו שעבור $T=1$ מתקיים

$$P_T(x|s) = P(x|s)$$

לכל מילה x ורישא s .

ג. (10 נק') בהינתן s , לאיזו התפלגות שואפת ההתפלגות $P_T(x|s)$ כאשר T שואף ל-0?

ד. (10 נק') נניח שההתפלגויות המותנות $P(x|s)$ (עבור ה- s השונים) נאמדו באמצעות אומד נראות מרבית

(Maximum Likelihood Estimator) והוחלקו באמצעות add- δ smoothing. כמו כן, נניח שערך ה- δ שנבחר גדול מדי, כלומר היחס בין ההסתברות של מילים (x) שכיחות בהינתן הרישא (s) לבין ההסתברות של מילים נדירות בהינתן הרישא, נמוך מדי. מדוע זו עשויה להוות בעיה בשימוש במודל השפה? האם דגימה באמצעות טמפרטורה מתאימה יכולה להקל על הבעיה? הסבירו בפירוט את תשובתכם.

ה. (10 נק') נניח כעת שנרצה להשתמש במודל השפה כדי לדגום מגוון משפטים, ולהציגם בפני המשתמשים על

מנת שיוכלו לבחור את המתאים ביותר עבורם. כדי לעשות כן, נרצה להרחיב את הדגימה באמצעות

טמפרטורה כך שתאפשר לדגום $k \in \mathbb{N}$ (מספר טבעי נתון) של משפטים שונים באמצעות beam search. הגדירו באופן פורמלי שיטה לעשות זאת (תשובה לא פורמלית לא תתקבל).

שאלה 3 (40 נקודות):

בשאלה זו נעסוק בבעיית סיווג כתבות בעיתון לפי המדינה העיקרית בה מתרחשת הכתבה. נתונה קבוצה סופית של שמות מדינות L . בהינתן מסמך, נרצה לחזות את התווית המתאים ביותר עבורו מתוך L . למשל, כתבה העוסקת בדיונים בכנסת תקבל תווית "ישראל", בעוד שכתבה שעוסקת בשיפוץ מגדל אייפל תקבל תווית "צרפת".

א. (10 נק') תארו באופן פורמלי מודל מסוג Naïve Bayes עבור הבעיה. התכונות (features) של הבעיה יהיו בינריות מסוג bag of words. אין צורך לתאר את תהליך האימון וההיסק (inference).

ב. (5 נק') מהן הנחות אי התלות המותנה (conditional independence) שאותן המודל מניח?

ג. (15 נק') נניח כעת שזהות צירופי המילים הסמוכות (bigrams) הן תכונות חזקות לתווית המסמך, בעוד

שזהות המילים הבודדות (unigrams) הן תכונות חלשות באופן יחסי (נסמן הנחה זו ב-A). האם ההנחות של

מודל Naïve Bayes מתאימות לשימוש בתכונות מסוג bigrams? אם כן, הסבירו, אם לא, הציעו מודל

הסתברותי אחר (שנלמד בכיתה) עבור הבעיה שעשוי להתאים יותר.

כעת נתבונן במשימה בה נתון ספר המחולק לרצף של מסמכים $(d_1, \dots, d_n)$. כמו במשימה הקודמת, נרצה לסווג כל מסמך לתווית מתוך L . כמו כן, ידוע שהתווית של מסמך היא תכונת חזקה לתווית של המסמך הבא (נסמן הנחה זו ב-B).

ד. (10 נק') תארו באופן פורמלי מודל הסתברותי לבעיה המנצל את הנחות (A) ו-(B). נמקו את תשובתכם.

חלק ב' (20 נקודות): ענו על בדיוק שאלה אחת מבין שאלות 4-5

שאלה 4 (20 נקודות):

שאלה זו תעסוק בממד האבלואציה BLEU עבור תרגום מכונה (Machine Translation). עבור תרגום משפט נתון x , נניח שנתונים התרגומים המוצעים (candidates) הבאים:

1. NLP is data-driven, but this was not the case before
2. NLP is driven by data, but this wasn't the case before

כמו כן נתון reference יחיד עבור אותו המשפט:

1. NLP is data-driven, but this wasn't the case before

א. (10 נק') הגדירו את המטריקה BLEU. הניחו שאנו משתמשים רק ביוניגרמים (unigrams) וביגרמים (bigrams) בחישוב המטריקה. אין צורך להגדיר את ה-brevity term.

ב. (10 נק') כעת נניח שמשתמשים ב-BLEU רק עם יוניגרמים (ללא ביגרמים או n -grams מסדר גבוה יותר) וללא brevity term. הציעו שתי חלוקות של התרגומים המוצעים ל-tokens, כך שעל פי חלוקה אחת התרגום המוצע הראשון יקבל ניקוד גבוה יותר, ועל פי החלוקה השנייה התרגום המוצע השני יקבל ניקוד גבוה יותר.

שאלה 5 (20 נקודות):

א. (10 נק') בשאלה זאת נעסוק ב-MST Parser שנלמד בכיתה עבור Dependency Parsing. הגדירו את פונקציית הניקוד (scoring function) עבור עצי תלויות (dependency trees) שבה האלגוריתם משתמש. הגדירו במדויק את כל המושגים המשמשים אתכם בתשובתכם. מהם הפרמטרים של המודל?

ב. (10 נק') הגדירו תכונת (feature) העשויה להיות שימושית ב-Graph-based Dependency Parsing ושאינה ניתנת לייצוג באמצעות פונקציית הניקוד שהגדרתם בסעיף א'. הגדירו פונקציית ניקוד שבמסגרתה ניתן לייצג את התכונת. הסבירו את תשובתכם.

בהצלחה!