

תאריך: 5.3.2023

מבחן מועד ב' בקורס עיבוד שפה טבעית (67658)

שנת לימודים התשפ"ג 2022/2023

משך המבחן: שעותיים

מרצה הקורס: פרופ' עמרי אבנר

השימוש בכל חומר עזר אסור, נא כתבו על הכריכה על אילו שאלות עניתם.

חלק א' (80 נקודות): ענו על בדיוק שתי שאלות מבין שאלות 1-3

שאלה 1 (40 נקודות):

בשאלה זו נעסוק במודלי שפה מרקובים מסדר גבוה (n-gram Language Models).

א. (5 נק') הגדירו באופן פורמלי מודל שפה מרקובי מסדר n , עבור n טבעי כלשהו.

ב. (5 נק') הסבירו כיצד ניתן לחשב את אומד הנראות המרבית (Maximum Likelihood Estimator) עבור המודל שהגדרתם בסעיף א'. אין צורך להוכיח שהאומד שהגדרתם אכן ממקסם את הנראות (Likelihood).

ג. (10 נק') האם ניתן לתאר את השפה האנגלית במדויק על ידי מודל מסדר n ? נמקו את תשובתכם באמצעות דוגמא.

ד. (8 נק') האם תשובתכם לסעיף ג' תשתנה עבור מודל שפה המבוסס על Recurrent Neural Network? נמקו את תשובתכם.

ה. (12 נק') נניח שנתונה שפה הניתנת למידול באופן מדויק ע"י מודל שפה מרקובי מסדר n . האם ישנם חסרונות בשימוש במודל מסדר $n+1$? אם כן, מהם?

שאלה 2 (40 נקודות):

נתונים שלושה מודלי שפה (Language Models). נסמן את פונקציית ההסתברות שהם מתארים ע"י P_{M1} , P_{M2} , P_{M3} . נרצה לבנות מודל שפה חדש המשלב את היתרונות של שלושת המודלים על ידי אינטרפולציה ביניהם.

נגדיר מודל שפה חדש M ע"י:

$$P_M(x_n | x_1, \dots, x_{n-1}) = \lambda_1 P_{M1}(x_n | x_1, \dots, x_{n-1}) + \lambda_2 P_{M2}(x_n | x_1, \dots, x_{n-1}) + \lambda_3 P_{M3}(x_n | x_1, \dots, x_{n-1})$$

כאשר $\lambda_1, \lambda_2, \lambda_3$ הם מספרים ממשיים.

א. (10 נק') הציגו תנאי הכרחי ומספיק על $\lambda_1, \lambda_2, \lambda_3$ על מנת ש- P_M יגדיר התפלגות חוקית לכל P_{M1}, P_{M2}, P_{M3} ? הוכיחו את טענתכם.

ב. (15 נק') נניח שנרצה להפעיל את מודל השפה M על טקסטים הלקוחים מאתרי ספורט. נתון קורפוס C שנלקח מאתרי ספורט. הציגו שיטה לקבוע את הערכים של $\lambda_1, \lambda_2, \lambda_3$ על מנת להתאים את M לעבודה על אתרי ספורט. רשמו את כל הנוסחאות המשמשות אתכם.

הערה: אין צורך להסביר כיצד פותרים את בעיית האופטימיזציה, אלא רק להגדיר מהי בעיית

האופטימיזציה אותה יש לפתור.

- ג. (15 נק') נניח שידוע שהמודל M1 עובד טוב יותר מ-M2 ו-M3 בחיזוי (פרדיקציה) של המילה x_n כאשר x_{n-1} היא מילה המופיעה פחות מ-10 פעמים בקורפוס האימון, וגם שהמודל M2 עובד טוב יותר מ-M1 ו-M3 כאשר x_{n-1} היא מילה המופיעה יותר מ-100 פעמים בקורפוס האימון. עבור שאר המקרים לא ידוע מראש מהו היחס בין הביצועים של המודלים. אילו שינויים עליכם לבצע בשיטה שהצעתם בסעיף ב' על מנת לקחת בחשבון מידע זה?

שאלה 3 (40 נקודות):

- א. (10 נק') נתון מודל HMM (Hidden Markov Model) מסדר ראשון (Bigram), כך שהמצב החבוי (ה-
(hidden state) הוא זוג. נסמן את הערך החבוי (y_i, w_i) לכל i בשרשרת. הערך הגלוי (ה-observed value)
יסומן על ידי x_i . רשמו את הנוסחא להתפלגות המשותפת של המשתנים המקריים המתוארים על ידי המודל:
 $(x_1, w_1, y_1), (x_2, w_2, y_2), \dots, (x_n, w_n, y_n)$
- ב. (10 נק') מהם הפרמטרים של המודל בסעיף א'? כמה פרמטרים בסה"כ יש למודל? הניחו שהמשתנים
המקריים x_i לקוחים מתוך הקבוצה X שגודלה m_1 , המשתנים y_i לקוחים מתוך Y שגודלה m_2 , והמשתנים
 w_i לקוחים מתוך W שגודלה m_3 .
- ג. (10 נק') הניחו כעת שלכל i ו- j המשתנים המקריים y_i ו- w_j הם בלתי תלויים. כמו כן נניח שה- y_i מהווים
שרשרת מרקוב, וגם שה- w_i מהווים שרשרת מרקוב. רשמו מחדש את הנוסחא להתפלגות המשותפת של
המשתנים המקריים במודל. כמה פרמטרים יש במודל זה?
- ד. (10 נק') הסבירו מהי בעיית הדלילות בשערוך פרמטרים (sparsity). כיצד הנחת אי-התלות בסעיף הקודם
עשויה להקל עליה? ניתן להניח ששערוך הפרמטרים נעשה בשיטת אמידת נראות מרבית (Maximum
Likelihood Estimation).

חלק ב' (20 נקודות): ענו על בדיוק שאלה אחת מבין שאלות 4-5

שאלה 4 (20 נקודות):

- א. (10 נק') הסבירו מהו distant supervision וכיצד משתמשים בו ב-relation extraction.
- ב. (10 נק') מהו היתרון הפוטנציאלי של שימוש ב-semantic role labeling עבור relation extraction על פני
שימוש במבנים תחביריים בלבד?

שאלה 5 (20 נקודות):

- א. (10 נק') מהו Oracle עבור Transition-based Parsing? הסבירו מהו החיסרון העיקרי בגישה זו לאימון
Transition-based Parsers.
- ב. (10 נק') מהו Dynamic Oracle וכיצד שימוש בו עשוי להקל על החיסרון אשר תיארתם בסעיף א'?

בהצלחה!