

מבחן מועד ב' בקורס עיבוד שפה טבעית (67658)

שנת לימודים התשפ"ד 2023/2024

משך המבחן: שעותיים

מרצה הקורס: פרופ' עמרי אבנד

הנחיות:

- השימוש בכל חומר עזר אסור.
- נא כתבו על הכריכה על אילו שאלות עניתם.
- יש לנמק כל תשובה לשאלה גם אם לא נכתב כך במפורש. תשובה ללא נימוק לא תזכה בניקוד.

חלק א' (80 נקודות): ענו על בדיקת שתי שאלות מבין שאלות 1-3

שאלה 1 (40 נקודות):

- א. (7 נק') הגדירו מודל שפה מרקובי (Markov Language Model) מסדר k כלשהו (k טבעי גדול מ-0 כלשהו). אין צורך לתאר את תהליכי האימון (training) וההיסק (inference).
- ב. (7 נק') הראו שמודל מרקובי חבוי (HMM, Hidden Markov Model) עבור תיוג חלקי דיבר (Part of Speech Tagging) מגדיר מודל שפה (לאו דווקא מרקובי). נמקו.
- ג. (7 נק') האם מודל MEMM (Maximum Entropy Markov Model) עבור תיוג חלקי דיבר מגדיר גם הוא מודל שפה? נמקו.
- ד. (7 נק') תארו באופן פורמלי את שיטת ההחלקה של Kneser-Ney עבור מודל שפה מרקובי מסדר ראשון (bigram).
- ה. (12 נק') תארו שיטת החלקה של הסתברויות הפליטה (emission probabilities) במודל HMM עבור תיוג חלקי דיבר, המבוססת על שיטת Kneser-Ney. האם שימוש כזה מיתר את הצורך בשימוש ב-Pseudowords להחלקה? נמקו.

שאלה 2 (40 נקודות):

- א. (10 נק') הגדירו באופן פורמלי מהו מודל CRF (Conditional Random Field) מסדר ראשון (bigram). אין צורך לתאר את תהליכי האימון (training) וההיסק (inference).
בהינתן מודל CRF מסדר ראשון הפועל על סדרה של מילים $x_1, \dots, x_n$, נסמן ב- $y_1, \dots, y_n$ את התגיות (labels) המתאימות לכל מילה. נניח שהתגיות לקוחות מקבוצה סופית נתונה L .
- ב. (30 נק') כתבו פסאודו-קוד שמקבל כקלט מודל bigram CRF (מסמנו M), ומשפט הנתון כסדרה של מילים $x_1, \dots, x_n$ כאשר $n \geq 6$, ומחזיר את ההסתברויות $P(y_2=t_1, y_4=t_2, y_6=t_3 | x_1, \dots, x_n)$ לפי המודל M לכל שלשת תגיות $t_1, t_2, t_3 \in L$. הערה: כלומר, הפלט של הפונקציה הוא מילון.

שאלה 3 (40 נקודות):

- א. (10 נק') הסבירו מהו מגנון ה-multi-head attention ב-Transformer. אין צורך להסביר כיצד פועל כל head בנפרד, אלא רק כיצד מקבלים multi-head attention מתוך attention עם head יחיד. לוו את הסברכם

בנוסחאות.

כעת הניחו שנתון מודל Transformer מאומן עבור תרגום מעברית לאנגלית. נסמנו ב-M. כמו כן, נשתמש בסימונים הבאים : משפט המקור (הקלט ל-M) יסומן ב-s, בעוד שהפלט יסומן ב- $t_1, \dots, t_n$, כאשר כל t_i הוא token. ב. (15 נק') הציעו שיטה הרצה בזמן פולינומיאלי המקבלת כקלט משפט s ואת M, ומחזירה את ההתפלגות של ה-token השני בפלט של M. כלומר את $P(t_2|s)$ לפי M עבור כל ערך אפשרי ל- t_2 באוצר המילים. ג. (15 נק') הרחיבו את השיטה שהצעתם בסעיף ב' לשיטה המקבלת כקלט משפט s, ומספר טבעי i, ומחזירה את ההתפלגות של ה-token ה-i בפלט של M. כלומר את $P(t_i|s)$ לפי M עבור כל ערך אפשרי ל- t_i באוצר המילים. האם השיטה שהצעתם רצה בזמן פולינומיאלי?

חלק ב' (20 נקודות): ענו על בדיוק שאלה אחת מבין שאלות 4-5

שאלה 4 (20 נקודות):

א. (5 נק') הגדירו פורמלית מהו מדד perplexity עבור אבלואציה (evaluation) של מודלי שפה.
ב. (15 נק') נעסוק בסעיף זה במודל BERT. הסבירו בקצרה מהו הקלט והפלט של המודל, כיצד הוא מאומן (כולל loss function) וכיצד עובד תהליך ה-fine-tuning. אין צורך להסביר כיצד עובד מנגנון ה-self-attention או לתאר את המבנה הפנימי של הרשת. כמו כן, אין צורך לתאר את האימון על Next Sentence Prediction.

שאלה 5 (20 נקודות):

א. (10 נק') הגדירו באופן פורמלי את שיטת האבלואציה BLEU עבור תרגום מכונה (machine translation).
ב. (10 נק') תארו את המגבלות של BLEU כשיטת אבלואציה לתרגום מכונה.

בהצלחה!