

תאריך: 11.2.2024

מבחן מועד א' בקורס עיבוד שפה טבעית (67658)

שנת לימודים התשפ"ה 2024/2025

משך המבחן: שעותיים

מרצה הקורס: פרופ' עמרי אבנד

הנחיות:

- השימוש בכל חומר עזר אסור, מלבד דף נוסחאות שאושר מראש על ידי צוות הקורס (לאלו הזכאים לכך).
- יש לנמק כל תשובה לשאלה גם אם לא נכתב כך במפורש. תשובה ללא נימוק לא תזכה בניקוד.
- נא כתבו על הכריכה על אילו שאלות עניתם.

חלק א' (80 נקודות): ענו על שתי שאלות מבין שאלות 1-3

שאלה 1 (40 נקודות):

משימת החלוקה לפרקים היא משימה בה נתון כקלט מסמך ארוך בו סימוני סופי הפרקים נמחקו. מסמך בשאלה זו הוא סדרת משפטים $s_1, \dots, s_n$. פלט המשימה הוא רשימה של אינדקסים $0 < i_1 < i_2 < \dots < i_k < i_{k+1} = n$ המסמנים את נקודות הסוף של הפרקים (כלומר את האינדקס של המשפט האחרון בכל פרק). לדוגמא, עבור קלט s_1, s_2, s_3, s_4 , קיימות שלוש אפשרויות לפלט בו שלושה פרקים:

$s_1 s_2_s_3_s_4$ ($i_1=2, i_2=3, i_3=4$)

$s_1_s_2_s_3 s_4$ ($i_1=1, i_2=2, i_3=4$)

$s_1_s_2 s_3_s_4$ ($i_1=1, i_2=3, i_3=4$)

א. (15 נק') בסעיף זה נניח ש- k נתון מראש כחלק מהקלט. הגדירו מודל לוג-ליניארי אשר מקבל מסמך $s_1, \dots, s_n$ ואינדקס $0 < i < n$ ומחזיר הסתברות לכך שבמסמך הקלט היה במקור סוף פרק אחרי s_i . היסק באמצעות מודל זה יתבצע על ידי מתן ציון לכל ערך אפשרי ל- i , ובחירת k הערכים אשר מעניקים הסתברות מקסימלית כפלט המודל. השתמשו ב-bag of words representation כתכונות (features). על התכונות להסתמך על ששת המשפטים $s_i, s_{i-1}, s_{i-2}, s_{i+1}, s_{i+2}, s_{i+3}$. יש להגדיר במדויק הן את המודל והן את פונקציית התכונות.

ב. (10 נק') כעת נניח שמניתוח מדויק יותר של הבעיה עולה האבחנה שההשפעה של הופעת מילה אחרי נקודת סיום הפרק הנבחנת (האינדקס i) שונה מההשפעה של הופעת מילה לפני נקודת הסיום הנבחנת (נסמן הנחה זו ב-A). האם המודל שהצגתם בסעיף א' יכול לתפוס את האבחנה הזאת? אם כן, נמקו. אם לא, הציעו שינוי למודל מסעיף א' שיכול להשתמש באבחנה זו.

ג. (15 נק') בסעיף זה k נקבע על ידי האלגוריתם ולא נתון מראש. הגדירו באופן מדויק מודל Bigram CRF עבור הבעיה. כמו כן, הציעו פונקציית תכונות עבור הבעיה, המבוססת על bag of words features של שלושת המשפטים לפני ואחרי נקודת סיום הפרק הנבחנת, ומניחה את הנחה A מסעיף ב'. מהם היתרונות והחסרונות של שימוש בגישה זו, לעומת הגישה מסעיף א'?

הערה: אין צורך לתאר את האימון (training) וההיסק (inference).

תשובה:

א.

$$p(y|x; w) = \frac{\exp(w \cdot \phi(x, y))}{\sum_{y'} \exp(w \cdot \phi(x, y'))}$$

$\swarrow$ $score(x, y, w)$

עם y בינארי (לחתוך או לא), פי מקבל את כל הקטע ובונה את ה-BOW לפי המשפטים הרלוונטים (וקטור באורך אוצר המילים או פי 2 מאוצר המילים אם משתמשים ב-block notation), ו- w המשקולות הנלמדות (בגודל וקטור הפיצ'רים).

ב.

לא יכול לתפוס כי BOW מתעלם מהמיקום של המילים.
פיתרון אפשרי – וקטור התכונות יהיה באורך כפול, אחד עבור ה-BOW הימני ואחד עבור השמאלי.

ג.

הגדרת CRF:

$$P(y|x) = \frac{\prod_{j=1}^{n(i)} e^{f(j, y_j, y_{j-1}, x)^T \cdot w}}{Z(x; w)}$$

$$Z(x; w) = \sum_y \prod_{j=1}^{n(i)} e^{f(j, y_j, y_{j-1}, x)^T \cdot w}$$

כמו קודם, y בינארי. פונקציית הפיצ'רים מקבלת את כל המשפטים (x) אך בונה ייצוג רק לפי המקום הנוכחי (j).
הפונקציה בונה וקטור בו יש את הפיצ'רים של BOW וזה משוכפל לפי מספר המעברים (כלומר מכפילים ב- 2×2).
לחילופין, אפשר להגדיר תכונות מעברים (2×2) ותכונות "פליטה" המותנים רק ב- y_j .

חסרונות:

- צריך אימון עם משפטים שלמים (ויותר דאטה).
- הכל יותר מסובך מבחינה חישובית (אימון והסקה).
- חיסרון אפשרי נוסף – קשה לקבוע מראש את k .

יתרונות:

- מתחשב במעברי פסקה אחרים. לדוגמא, המרווח בין מעברים יכול להשפיע.
- יתרון אפשרי – לא צריך לקבוע מראש את k .

הדגשות:

- לא להוריד אם לא ציינו את המשמעות מבחינת k

שאלה 2 (40 נקודות):

בשאלה זאת נעסוק בניתוח לפי מבני תלויות (dependency parsing) של משפטים מחוברים. משפט מחובר הוא משפט מהצורה s_1 and s_2 כאשר s_1 ו- s_2 הן פסוקיות (clauses) המחוברות על ידו. לדוגמא, המשפט

I went home and took a shower


הוא משפט מחובר, בו s_1 הוא "I went home" ו- s_2 הוא "took a shower".

לעומת זאת, המשפט

John and Mary got married

אינו משפט מחובר, שכן ה-"and" מחבר בין "John" ו-"Mary" ולא בין שתי פסוקיות.

כמו כן, נתון שניתוח התלויות של משפטים מחוברים מהצורה s_1 and s_2 הוא מהצורה:



כאשר T הוא תת-עץ התלויות על מילות s_1 ו- T_2 הוא תת-עץ התלויות על מילות s_2 .

נניח שכל המשפטים בשפה הם או משפטים מחוברים הכוללים שני משפטים שאינם בעצמם מחוברים, או משפטים לא מחוברים. כלומר, כל משפט יכול להיכתב או כ- s_1 and s_2 או כ- s_1 , כאשר s_1, s_2 הם משפטים לא מחוברים.

א. (15 נק') הציעו אלגוריתם המבוסס על fine-tuning של BERT אשר מקבל משפט כמחרוזת של מילים, וקובע את מיקום המילה and המחברת בין פסוקיות, אם ישנה כזאת. תארו את האלגוריתם, כולל תהליך ההיסק (inference) ותהליך ה-fine-tuning (בהינתן דאטה מתויג עבור משימה זו). אין צורך לתאר את תהליך ה-pretraining.

ב. (25 נק') נניח כעת שאלגוריתם MST Parser מציג ביצועים גבוהים בניתוח משפטים שאינם מחוברים, אך מציג ביצועים נמוכים בניתוח משפטים מחוברים. כמו כן, נניח שהאלגוריתם שהצגתם בסעיף א' מציג ביצועים גבוהים במשימתו. הציעו כיצד ניתן לשנות את אלגוריתם ההיסק (inference), כך שהאלגוריתם יציג ביצועים טובים על משפטים מחוברים. אין צורך לפרט את פרטי אלגוריתם Chu-Liu-Edmonds.

תשובה:

א.

מסירים את השכבה האחרונה של ה-BERT (הליניארי והסופט-מקס) ומוסיפים שכבת קליסיפיקציה בינארית ברמת הטוקן. יש כמה אפשרויות להגדיר את ה-label: 0 זה and שמחבר בין משפטים ו-1 זה כל דבר אחר, 0 זה משפט ראשון ו-1 משפט שני וכו'. האימון מתבצע באופן supervised על מודל שאותחל מה-Pretraining. בשלב ההסקה מכניסים משפט ולכל ייצוג של מילה במשפט יש את המסווג המאומן שקובע האם יש כאן and מחבר או לא.

ב.

1. מוצאים האם ואיפה יש and מחבר.

2. אם אין, מחזירים את ה-MST על הכל.

3. אם יש,

* אז מפעילים את ה-MST על כל חלק.
* מחברים את שני העצים כפי המתואר בשאלה

שאלה 3 (40 נקודות):

בשאלה זו נעסוק ב-Trigram Language Models, כלומר מודלי שפה מרקוביים מסדר שני.
א. (10 נק') הסבירו מהי בעיית דלילות הנתונים בשערוך language models. האם בעיה זו מובילה בהכרח להערכת חסר של ההסתברויות של מילים נדירות או שמא היא עשויה לעיתים להוביל להערכת יתר של ההסתברויות שלהן?

בהמשך השאלה תציעו אפשרות להרחיב את החלקת Knaser-Ney למודלים מסדר שני. בהינתן מודל שפה P מרקובי מסדר שני, נגדיר את ההתפלגות המוחלקת של מילה w בהינתן זוג מילים u, v על ידי:

$$P(w|v, u) = \frac{\max\{\text{count}(u, v, w) - d, 0\}}{\text{count}(u, v)} + \lambda(u, v) \cdot q(w|v)$$

כאשר $\text{count}(u, v, w)$ הוא מספר ההופעות של הרצף (u, v, w) בקורפוס האימון ו- $\text{count}(u, v)$ הוא מספר ההופעות של הרצף (u, v) בקורפוס האימון. d הוא מספר ממשי חיובי קטן מ-1. q היא הסתברות המעבר בין w ל- v לפי מודל מרקובי מסדר ראשון (bigram), מוחלקת על פי שיטת Knaser-Ney.

ב. (10 נק') כיצד יש להגדיר את $\lambda(u, v)$? נמקו את תשובתכם.
ג. (20 נק') נבחן חלופה בה נגדיר את q כאומד הנראות המרבית (Maximum Likelihood Estimator) של מודל מרקובי מסדר ראשון, ללא החלקה. האם שימוש באפשרות זאת מגדיר התפלגות מעברים $P(w|u, v)$ חוקית? אם כן, מה החיסרון שלה על פני שימוש בהתפלגות מוחלקת על פי שיטת Knaser-Ney בהקשר זה.

תשובה:

א. בעיית דלילות הנתונים היא חוסר היכולת לשערף את הפרמטרים באופן אמין בהינתן הדאטה. הבעיה היא שמספר הפרמטרים הוא עצום (גודל אוצר המילים בשלישית), ומעבר לכך ההתפלגות היא מאוד מוטה, ועל יהיו הרבה מאוד אירועים (כלומר הופעה של שתי מילים קודמות) נדירים. על כן, ביחס להרבה מאוד מילות הקשר, הקורפוס לא ייצג בצורה טובה את מספר המילים מסוג מסוים שבאות אחריהם.

זה יוביל להערכת חסר של הסתברויות של מילים שלא הופיעו, אך גם להערכת יתר של הסתברויות מילים נדירות שבמקרה כן נכנסו (ולא נוכל להעריך עד כמה הן באמת נדירות). לדוגמא, עבור הפעה של זוג מילות הקשר נדיר (talented aardvark) נקבל, נניח, 5 הופעות בקורפוס, ולכן כל אחת מהמילים תקבל בחישוב MLE פשוט התסברות השווה לכפולה של 0.2.

ב.

כמו בביגרם (c כוכבית זה אחרי שמורידים d מהספירות).

$$\lambda(w_{i-1}) = 1 - \sum_w \frac{c^*(w_{i-1}, w)}{c(w_{i-1})}$$

או (מדובר בביטויים שקולים)

$$\lambda(w_{i-1}) = \frac{d}{c(w_{i-1})} |\{w : c(w_{i-1}, w) > 0\}|$$

רק במקום w_{i-1} לשים u, v .

הסיבה לכך היא שזהו הערך כך ש- $P(w|u, v)$ יסתכם ל-1 על פני כל הערכים האפשריים ל- w .

ג. כן, זה חוקי (מקיים את אקסיומות ההסתברות). כל התנאי על q הוא להגדיר התפלגות חוקית (ביגרם). החיסרון הוא שאין החלקה בביגרם (אז אם יש זוג מילים שלא הופיע הוא יקבל הסתברות 0).

חלק ב' (20 נקודות): ענו על בדיוק שאלה אחת מבין שאלות 4-5

שאלה 4 (20 נקודות):

תארו את תהליך האימון של Encoder-decoder Transformer עבור Machine Translation. בתשובתכם התייחסו לסוג הדאטה הנדרש, ל-loss function ולאלגוריתם האימון. אין צורך לתאר בפירוט את ארכיטקטורת ה-Transformer.

תשובה:

דאטה – זוגות של מקור ותרגום, המומר לדוגמת אימון שהיא משפט המקור ורישא כלשהי של התרגום, כך שהמילה הבאה היא הפלט הנכון.

פונקציית לוס – cross entropy עבור ניבוי של המילים בתרגום (ב-decoder).

אלגוריתם אימון – מעבירים מקור ב-encoder, הקידוד שלו נכנס ל-decoder. ה-decoder מנבא מילה בתרגום המתויג בהינתן המילים שלפניו ועושה backpropagation לפי הלוס.

שאלה 5 (20 נקודות):

א. (10 נק') הסבירו כיצד לאמן מערכת relation extraction באמצעות גישת ה-distant supervision.

ב. (10 נק') בקורס דברנו על כך שנהוג להשתמש בגישת ה-distant supervision עבור relation extraction

כאשר זמינה כמות גדולה של דאטה לאימון (training data). הסבירו מה הקושי בו ניתקל אם ננסה

להשתמש בגישה זו עם כמות קטנה של דאטה לאימון.

תשובה:

א. לפעמים יש לנו תיוג על משהו שמופיע בטקסט אבל אין פרטים מדויקים על איך ואיפה. במקרה כזה פשוט

נקח את כל המשפטים שבהם יש את זוג הישויות שאנו יודעים עליהם את הקשר המסוים ונגדיר אותן

כדוגמאות אימון.

```

function DISTANT SUPERVISION(Database D, Text T) returns relation classifier C

  foreach relation R
    foreach tuple (e1, e2) of entities with relation R in D
      sentences  $\leftarrow$  Sentences in T that contain e1 and e2
      f  $\leftarrow$  Frequent features in sentences
      observations  $\leftarrow$  observations + new training tuple (e1, e2, f, R)
  C  $\leftarrow$  Train supervised classifier on observations
return C

```

ב. השיטה מייצרת גם לייבלים שהם רעש (משפטים שבהם יש את שתי הדמויות אבל הקשר אחר). במקרה של דאטה רועש נצרכת כמות גדולה כדי שהרעש יסונן.

בהצלחה!