

תאריך: 11/3/2025

מבחן מועד ב' בקורס עיבוד שפה טבעית (67658)

שנת לימודים התשפ"ה 2024/2025

משך המבחן: שעותיים

מרצה הקורס: פרופ' עמרי אבנד

הנחיות:

- השימוש בכל חומר עזר אסור, מלבד דף נוסחאות שאושר מראש על ידי צוות הקורס (לאלו הזכאים לכך).
- יש לנמק כל תשובה לשאלה גם אם לא נכתב כך במפורש. תשובה ללא נימוק לא תזכה בניקוד.
- נא כתבו על הכריכה על אילו שאלות עניתם.

חלק א' (80 נקודות): ענו על בדיקת שתי שאלות מבין שאלות 1-3

שאלה 1 (40 נקודות):

בשאלה זו נעסוק במשימת ה-sentiment analysis עבור ביקורות סרטים. נעסוק בסיווג ביקורות כחיוביות או שליליות (polarity). נבחן שלוש גישות:

- (1) שימוש במודל Naive Bayes עם תכונות (features) bag of words של המילים בביקורת.
 - (2) שימוש במודל לוג-ליניארי עם וקטור תכונות המתקבל על ידי ממוצע ה-word2vec embeddings של כל המילים בביקורת.
 - (3) שימוש במודל BERT שעבר fine-tuning למשימה זו.
- נניח שנתונים לנו שני סוגים של דאטה: אוסף גדול של טקסטים לא מתויגים (ניתן להניח שמכיל מספר מופעים של כל מילה בשפה), וכמות קטנה יחסית של טקסטים מתויגים בתגיות חיוביות או שליליות.
- א. (10 נק') הסבירו לגבי כל אחד מהמודלים, האם וכיצד ניתן להשתמש בשני סוגי הדאטה בתהליך האימון של המודל. אין צורך לתאר את פרטי אלגוריתמי האימון.

תשובה:

- (1) – רק בחלק המתויג. משתמשים כדי לאמן את כל הפרמטרים..
- (2) – בחלק הלא מתויג בשביל לאמן word2vec ובחלק המתויג בשביל הלוג-ליניארי.
- (3) – בחלק הלא מתויג בשביל pretraining ובחלק המתויג בשביל finetuning.

ב. (10 נק') נניח כעת שבאימון מודל (1) נשתמש בהחלקה באמצעות פסאודו-מילים (pseudowords). האם ניתן לצפות שרשימת פסאודו-מילים שנבנתה עבור תיוג חלקי דיבר (POS tagging) תהיה אפקטיבית גם במקרה זה? פרטו.

תשובה:

לא, כי צריך שהקטגוריות יהיו אינפורמטיביות עבור הבעיה הספציפית. כלומר, לקבץ יחד מילים כך שבהינתן המילה, ניתן לצפות שההסתברות של סנטימנט חיובי פחות או יותר דומה.

ג. (10 נק') האם סביר שתצמח תועלת משמעותית משימוש בפסאודו-מילים במקרים של מודלים (2), (3)? בכל אחד מהמקרים, אם צפויה תועלת, הסבירו כיצד ניתן להשתמש בפסאודו-מילים במקרה זה, ואם לא צפויה, הסבירו מדוע.

תשובה :

לא. כי word2vec ו-BERT משתמשים בייצוגים שכבר לוקחים בחשבון אספקטים סמנטיים אז התועלת, אם בכלל, תהיה מינימלית.

ד. (10 נק') הסבירו לגבי מודלים (1) ו-(3), כיצד הם עשויים להתמודד (אם בכלל) עם סיווג משפטים המכילים מילת שלילה, כמו "not" באנגלית או "לא" בעברית.

תשובה :

מודל (1) לא יצליח להתמודד כי מסתכלים על הסתברות של מילה בהינתן הקטגוריה באופן בלתי תלוי במילים אחרות. לכן ההימצאות של not לא תשפיע על ההסתברות של המילים האחרות, ו-not עצמה תהיה די נייטרלית. מודל (3) יוכל להתמודד באופן עקרוני כי יש ייצוג שנבנה מקשרים בין כל המילים במשפט (contextualized embeddings).

שאלה 2 (40 נקודות) :

א. (10 נק') בשאלה זו נעסוק במודל שפה מבוסס RNN (Recurrent Neural Network). כיצד עומק גרף החישוב (computational graph) עולה כפונקציה של מספר המילים הכולל בטקסט אותו אנו מעריכים? ענו במושגי סדר הגודל האסימפטוטי של העלייה, ולא בנוסחא מדויקת.

תשובה :

סדר הגודל הוא לינארי באורך המשפט. מספר הפעולות לכל מילה הוא קבוע ללא תלות באורך המשפט עד כה.

ב. (15 נק') הסבירו כיצד פועל מנגנון ה-multi-head self-attention וכיצד הוא שונה מ-single-head self-attention. אין צורך לפרט כיצד פועל מנגנון ה-self-attention.

תשובה :

יש כמה מטריצות attention שלפיהן בונים ייצוג לכל מילה. בסוף משרשרים את כל הייצוגים ומכפילים ב- W^O כדי להחזיר למימד של ייצוג אחד.

ג. (15 נק') נניח כעת שעל מנת לחסוך בפרמטרים, הוחלט להשתמש באותן מטריצות W^V, W^K, W^Q לכל ה-heads. מהו האפקט שפעולה זו תיצור? התייחסו בתשובתכם גם למטריצה W^O .

תשובה :

בגלל שהמטריצות זהות הפעולה של כל ראש היא זהה. השרשור והמכפלה לא יהיו יותר אקספנסיביים מאשר ראש בודד. W^O גם לא ישנה את המצב שכן הוא פשוט שקול להפעלת טרנספורמציה ליניארית על מטריצת האקטיבציות (ערכי ה-Z).

שאלה 3 (40 נקודות) :

נגדיר משימה של הוספת סימני פיסוק למשפטים ללא סימני פיסוק. סימני הפיסוק אליהם אנו מתייחסים הם : נקודה, פסיק, סימן שאלה וסימן קריאה. באופן פורמלי, הקלט הוא משפט הנתון כסדרה של מילים $w_1, w_2, \dots, w_k$ (ללא סימני פיסוק), והפלט הוא סדרה של מילים וסימני פיסוק $w'_1, w'_2, \dots, w'_k$ כך ש- $k' \geq k$, וכך ש- $w_1, w_2, \dots, w_k$ הוא תת-סדרה של $w'_1, w'_2, \dots, w'_k$, ושאר האיברים הם סימני פיסוק. לצרכי שאלה זו נניח שבין כל שני סימני פיסוק חייבת להופיע לפחות מילה אחת.

א. (10 נק') הגדירו מודל CRF מסדר ראשון (Bigram) עבור משימה זו. מהו מרחב התגיות במודל שהגדרתם? אין

צורך לתאר את תהליכי האימון (training) וההיסק (inference).

תשובה :

$$P(y|x) = \frac{\prod_{j=1}^{n(i)} e^{f(j, y_j, y_{j-1}, x)^T \cdot w}}{Z(x; w)}$$

$$Z(x; w) = \sum_y \prod_{j=1}^{n(i)} e^{f(j, y_j, y_{j-1}, x)^T \cdot w}$$

מרחב התגיות יסמן אם מופיע סימן פיסוק מייד אחרי המילה הנדונה. התגיות האפשריות : סימן שאלה, סימן קריאה, נקודה, פסיק, כלום.

ב. (10 נק') איזה סוג של דאטה נדרש על מנת לאמן מודל כזה? הציעו כיצד ניתן להשיג כמות גדולה של דאטה מסוג זה.

תשובה :

צריך משפטים ללא סימני פיסוק ואת סימני הפיסוק שלהם (עם המיקום במשפט). ניתן לקבל דאטה כזה בקלות אם לוקחים קורפוס מפוסק, מסירים את סימני הפיסוק ומשתמשים בהם בתור תגיות.

ג. (20 נק') נניח שנתון מודל CRF מאומן כפי שהגדרתם בסעיף א'. תארו אלגוריתם יעיל המקבל קלט (ללא סימני פיסוק) באורך באורך זוגי $k=2n$ (n טבעי) ומחזיר את ההסתברות על פי המודל, שהפלט יכיל סימן שאלה מייד אחרי המילה ה-n המקורית (w_n) וסימן קריאה מייד אחרי המילה המקורית האחרונה (w_{2n}).

תשובה :

כמו ב-forward backward.

מחשבים את גורם הנירמול כרגיל (לפי אלפא או בתא). את הסכימה עד n מחשבים כמו אלפא. אפשר לאפס את כל המשקלים מהתגים של המילה האחרונה ל-STOP חוץ מהתג של סימן קריאה ואז לחשב את בתא מהסוף עד n. באופן שקול, ניתן להפעיל את אלגוריתם Viterbi כאשר במקום מקסימום מבצעים סכימה, וכאשר מגבילים את מרחב התגיות של y_n לסימן השאלה, ואת מרחב התגיות של y_{2n} לסימן קריאה.

חלק ב' (20 נקודות): ענו על בדיק שאלה אחת מבין שאלות 4-5

שאלה 4 (20 נקודות) :

א. (10 נק') הגדירו מהו מדד perplexity עבור הערכה (evaluation) של מודלי שפה.

תשובה :

$$Perplexity = e^{-l} \quad l = \frac{1}{M} \sum_{i=1}^m \log P(s_i) = \frac{1}{M} \sum_{i=1}^m \sum_j \log P(x_j^{(i)} | x_1^{(i)}, \dots, x_{j-1}^{(i)})$$

M is the total number of tokens (words) in the test data

m is the number of sentences in the test data

הערות :

- צריך להסביר מהם הביטויים שבנוסחה או לפחות שיהיה ניכר שזה ברור להם
- חובה גם לתת חישוב על הסתברות של משפט לפי מילים (ולא רק $P(s)$ כלומר ההסתברות של משפט שלם).

ב. (10 נק') בהינתן כמות דאטה גדולה כרצוננו עבור האימון, ובהינתן כמות בלתי מוגבלת של זמן ומשאבי חישוב לאימון, האם ניתן לפתח מודל שפה בעל perplexity השואף ל-1?

תשובה :

לא, כי בשפה טבעית יש אקראיות שלא ניתנת להכרעה. לדוגמא יש הרבה משפטים שמתחילים ב-The ואי אפשר לדעת בוודאות את ההמשך.

שאלה 5 (20 נקודות) :

בשאלה זו נעסוק בניתוח תלויות מבוסס גרפים (graph-based dependency parsing).
א. (10 נק') הגדירו באופן פורמלי את ה-sibling model עבור משימה זו.

תשובה :

$$score(T) = \sum_{(i,j,k) \in V^3 | (i,j) \in T \& (i,k) \in T} score(i,j,k) + \sum_{(i,j) \in T} score(i,j)$$

$$score(i,j,k) = \theta_1^t \cdot \phi_1(i,j,k, x_{1:n})$$

$$score(i,j) = \theta_2^t \cdot \phi_2(i,j, x_{1:n})$$

ב. (10 נק') תנו דוגמא לתכונת (feature) שאותה לא ניתן לייצג באמצעות sibling model. התכונת לא צריכה בהכרח להיות כזו שתשפר את הביצועים במשימה.

תשובה :

כל תכונת שמתייחסת ליותר מ-3 קודקודים. אפשר גם תכונת שמתייחסת לשלושה קודקודים שלא יוצרים מבנה של sibling, למשל שיוצרים שרשרת (כמו ב-grandchild model).

בהצלחה!